



بخش اول: سیستم نمایش اعداد لگاریتمی (LNS)

مقدمه:

در این بخش به بررسی و پیاده‌سازی سیستم نمایش اعداد لگاریتمی، به عنوان جایگزینی برای سیستم‌های اعداد ممیز ثابت (Fixed-Point) و ممیز شناور (Floating-Point) می‌پردازیم. در این سیستم نمایش، اعداد را به صورت لگاریتم قدر مطلق آن، که یک عدد ممیز ثابت می‌باشد، و علامت آن عدد ذخیره می‌کنیم. این نمایش به ما اجازه می‌دهد که عملیات‌های ضرب و تقسیم (در حوزه اعداد حقیقی) را به ترتیب با عملیات‌های ساده جمع و تفریق انجام دهیم. یکی از چالش‌هایی که این سیستم نمایش اعداد ایجاد می‌کند، عملیات جمع و تفریق می‌باشد که معمولاً با تکنیک‌هایی مانند استفاده از LUT و یا Bit-Shift تقریب زده می‌شوند.

نمایش اعداد در حوزه LNS به صورت زیر می‌باشد:

$$\tilde{X} = (z_x, s_x, m_x)$$

که در آن z_x نشان می‌دهد که عدد صفر می‌باشد یا خیر و s_x علامت عدد را نمایش می‌دهد. مقدار واقعی صفر در حوزه LNS به صورت b^m قابل نمایش نیست، به همین جهت معمولاً در نمایش آن از یک بیت اضافه برای نمایش صفر استفاده می‌کنند. همچنین m_x (لگاریتم قدر مطلق عدد) یک عدد ممیز ثابت در نمایش مکمل دو با W بیت می‌باشد که f بیت از آن را بخش اعشار تشکیل می‌دهد.

در این بخش ابتدا به پیاده‌سازی توابع نرم‌افزاری تبدیل اعداد از حوزه حقیقی به LNS و بالعکس پرداخته و سپس توابعی برای محاسبات ضرب و جمع (با تقریب‌های مختلف) می‌نویسیم. در ادامه نیز به تحلیل نتایجی مانند خطای مطلق و نسبی در حوزه لگاریتمی به ازای پارامترهای مختلف از جمله عرض بیت نمایش LNS، تعداد بیت‌های بخش اعشار و یا مبنای انتخاب شده می‌پردازیم.

1- ابتدا توابع لازم برای تبدیل اعداد از حوزه حقیقی به LNS و بالعکس را بنویسید. فرمت اعداد در حوزه LNS را مطابق با توضیحات بالا در نظر بگیرید. لازم است که پارامترهای مبنای لگاریتم، طول بیت و تعداد بیت‌های اعشار را به عنوان ورودی همراه با عدد به این توابع بدهید تا تبدیل صحیح صورت گیرد.

برای درستی‌سنجی این توابع، با قرار دادن مبنای 2 و عرض بیت 6 (3 بیت برای بخش اعشار)، ابتدا بازه اعداد مثبت حقیقی که با این سیستم LNS قابل نمایش هستند را بدست آورده و سپس در جدولی نمایش LNS اعداد لیست زیر، معادل آن‌ها در حوزه حقیقی (پس از تبدیل نمایش لگاریتمی به حقیقی) و خطای مطلق و نسبی در حوزه حقیقی را گزارش کرده و نتایج را تحلیل کنید.

$$Test\ numbers = \{0.0, 1.0, 1.5, 0.25, -2.0, 12.0, 15, -7.5, 0.001\}$$

2- در این بخش می‌خواهیم به بررسی دقیق‌تر خطای ناشی از تبدیل اعداد از حوزه حقیقی به لگاریتمی پرداخته و تاثیر پارامترهایی نظیر عرض بیت و مبنا را بر این خطا بررسی نماییم. برای اینکار لازم است که به ازای هر یک از مجموعه پارامترهای مشخص شده در زیر، بازه اعداد مثبت حقیقی که با این سیستم LNS قابل نمایش هستند را بدست آورید. سپس تعداد مناسبی عدد (با توزیع یکنواخت) در تمام این بازه انتخاب کرده و خطای مطلق و نسبی را در نمودارهای جداگانه رسم کنید. همچنین لازم است که میانگین این خطاها را نیز گزارش کنید. در ادامه با مقایسه بازه قابل نمایش هر یک از 4 مجموعه زیر، مبنای انتخاب شده، تعداد بیت استفاده شده (W) و میانگین خطاهای نسبی آن‌ها، نتایج را تحلیل کرده و $Tradeoff$ های مشاهده شده را شرح دهید.

$$(base, W, f) = \{(\sqrt{2}, 8, 4), (2, 7, 4), (4, 6, 4), (16, 5, 4)\}$$

3- در این بخش به پیاده‌سازی توابع عملیات جمع در حوزه LNS می‌پردازیم. همانطور که در شکل زیر ملاحظه می‌کنید، ترم $\Delta \pm = \log_2(1 \pm 2^{-|m_1 - m_2|})$ پیاده‌سازی عملیات جمع را در این حوزه با مشکل مواجه می‌کند. برای رفع این چالش، ترم بالا با استفاده از LUT و یا $Bit-Shift$ تقریب زده می‌شود. لازم است که ابتدا یک تابع برای انجام عملیات جمع بنویسید که در آن عبارت Δ را به طور دقیق محاسبه میکند. سپس برای هر یک از تقریب‌های ذکر شده نیز تابع جمع مناسبی را پیاده‌سازی نمایید. در تقریب به وسیله LUT ، شما باید آرایه ای از مقادیر $\Delta \pm$ را به تعداد مشخص شده از پیش محاسبه کنید و هنگام عملیات جمع از مقدار مناسب از این مقادیر استفاده نمایید. در این بخش نیز لازم است پارامترهای مبنای لگاریتم، طول بیت و تعداد بیت‌های اعشار را به همراه ورودی‌ها به این توابع بدهید تا عملیات به درستی انجام شود.

$$sum = \begin{cases} \max(\tilde{n}_1, \tilde{n}_2) + \log_2(1 + 2^{-|\tilde{n}_1 - \tilde{n}_2|}), & \text{if } s_{n_1} = s_{n_2}, \\ \max(\tilde{n}_1, \tilde{n}_2) + \log_2(1 - 2^{-|\tilde{n}_1 - \tilde{n}_2|}), & \text{if } s_{n_1} \neq s_{n_2}, \end{cases}$$

برای درستی‌سنجی توابع، با قرار دادن مبنای 2 و عرض بیت 8 (4 بیت برای بخش اعشار)، به ازای هر یک از جفت ورودی‌های زیر، نتیجه جمع توسط هر یک از 3 تابع و همچنین خطاهای نسبی هریک از دو متد تقریب (نسبت به حاصل جمع بدون تقریب) را در جدولی گزارش کنید.

(در تقریب LUT ، تعداد هریک از $\Delta +$ و $\Delta -$ های از پیش محاسبه شده را 32 در نظر بگیرید)

$$(a, b) = \{(2.5, 3), (-4.75, -9.2), (0.25, 2.25), (4.5, 4.45), (-10, -10.2), (-2, 0)\}$$



4- در این بخش با همان پارامترهای تعیین شده در بخش قبل و با تعیین بازه اعداد مثبت حقیقی قابل نمایش، 1000 جفت عدد مثبت تصادفی در این بازه انتخاب کنید (میتوانید برای جلوگیری از سرریز شدن، رنج اعداد تصادفی را نصف بازه در نظر بگیرید). سپس حاصل جمع را توسط هر سه تابع برای آن ها محاسبه نموده و میانگین خطاهای نسبی و مطلق هر یک از دوتقریب (بر مبنای LUT و $Shift$) را محاسبه کرده و نمودار خطاها را نیز برحسب $|m_a - m_b|$ رسم کنید و نتایج بدست آمده را تحلیل نمایید. بررسی کنید که تغییر سایز LUT (برای مثال کاهش آن از 32 به 16) چه تاثیری بر خطای این روش خواهد داشت.

5- در این بخش تاثیر انتخاب مبنا را در بازه اعداد قابل نمایش و همچنین ارتباط آن با خطا را بررسی می کنیم. با تعیین عرض بیت 8 (4 بیت برای بخش اعشار) و برای مبناهای $\{10, 4, 2, \sqrt{2}\}$ ، رنج اعداد حقیقی قابل نمایش به ازای هر مبنا را محاسبه کرده و با انتخاب تعداد مناسبی عدد (با توزیع یکنواخت) در هر یک از این بازه ها، میانگین خطای نسبی را گزارش کنید. همچنین تحلیل کنید که در عرض بیت ثابت، انتخاب مبنا چگونه می تواند بر رنج اعداد و خطا تاثیر گذار باشد.

6- حال می خواهیم تاثیر استفاده از محاسبات LNS در شبکه های عصبی را با یک مثال ساده مشاهده کنیم. با تعیین عرض بیت 8 (4 بیت برای بخش اعشار) و مبنای 2، یک لایه شبکه عصبی که ورودی و فیلتر آن ابعاد $7 \times 7 \times 3$ دارند (و خروجی نتیجتاً یک عدد اسکالر خواهد بود) را به صورت تصادفی مقداردهی کنید (بازه اعداد ورودی را $[0, 4]$ و بازه اعداد فیلتر را $[-4, 4]$ در نظر بگیرید).

حال حاصل کانولوشن را یکبار در حوزه اعداد حقیقی انجام داده و بار دیگر با تبدیل ورودی ها و وزن ها به نمایش LNS ، عملیات های ضرب و جمع را در همان حوزه انجام داده و تنها پاسخ نهایی را به حوزه حقیقی تبدیل کنید (از توابع تبدیل، ضرب و جمع نوشته شده در بخش های قبل باید استفاده شود). محاسبات حوزه LNS را با استفاده از هر 3 تابع جمع کننده به طور جداگانه انجام داده و نتایج آن ها را با مقدار مورد انتظار مقایسه کرده و خطای هر کدام را گزارش کنید.

مواردی که باید تحویل دهید:

- کدها در قالب یک نوت‌بوک با پسوند *ipynb*، تهیه شوند، در پایان کار تمامی کد اجرا شده و خروجی هر سلول حتما در این فایل ارسالی ذخیره شده باشد. (برای مثال اگر خروجی سلولی یک نمودار است که در گزارش آورده‌اید، این نمودار باید در کدهای نوت‌بوک نیز وجود داشته باشد)
- خروجی‌های تست کیس‌ها مطابق روش‌هایی که ذکر شده‌اند.
- گزارش کار شامل یافته‌ها و نتایج و تحلیل آن‌ها (لطفا تمامی نکات و فرض‌هایی را که در پیاده‌سازی‌ها و محاسبات خود در نظر می‌گیرید در گزارش ذکر کنید)
- هدف از این تمرین، یادگیری شماسه! در صورت کشف تقلب، مطابق با قوانین درس برخورد خواهد شد.
- در صورت داشتن هرگونه سوال یا ابهام از طریق ایمیل زیر با دستیاران آموزشی در ارتباط باشید.

a.samoudi82@gmail.com

موفق باشید!